ÉCOLE NATIONALE SUPÉRIEURE D'ARTS ET MÉTIERS

Semestre 9 · Année universitaire 2026-2027

Cahier des charges

Deep Learning for Spare Parts Management

Pilotage conjoint de la maintenance et du stock de pièces de rechange d'une flotte de machines industrielles

Réalisé par Adam Elmadani

Encadré par Pr. Aziza Belmaati

Pr. Oumaima Bounou

Version 1.0, octobre 2026

Suivi du document

Version	Date	Objet	Rédaction
1.0	29/10/2026	Version initiale soumise à l'encadrement	A. Elmadani

Sommaire

1 Présentation du projet 3

1.1 Contexte . . . 3
1.2 Problématique . . . 3
1.3 Objectifs . . . 3

2 Périmètre et hypothèses 4

2.1 Périmètre . . . 4
2.2 Hypothèses de modélisation . . . 4

3 Description du système étudié 5

3.1 Fonctionnement d'une machine et du magasin . . . 5
3.2 Familles de machines et régimes de maintenance . . . 6
3.3 Défauts de fabrication . . . 7

4 Données 7

4.1 Jeu de données de référence . . . 7
4.2 Durées des étapes du processus . . . 8
4.3 Pièces, coûts et ressources . . . 9
4.4 Modèle de données . . . 10

5 Solution proposée 11

5.1 Simulateur à événements discrets . . . 11
5.2 Module de prédiction . . . 12
5.3 Agent d'apprentissage par renforcement . . . 13
5.4 Modèle de substitution . . . 14

6 Application web **14**

6.1 Objectif . . . 14

6.2 Exigences fonctionnelles . . . 15

6.3 Exigences non fonctionnelles . . . 15

6.4 Architecture . . . 15

7 Évaluation **16**

7.1 Politiques comparées . . . 16

7.2 Indicateurs de performance . . . 17

7.3 Protocole expérimental . . . 17

8 Choix techniques **17**

9 Organisation du projet **18**

9.1 Livrables . . . 18

9.2 Planning prévisionnel . . . 19

9.3 Risques . . . 19

10 Points restant à préciser **20**

Références **20**

1 Présentation du projet

1.1 Contexte

Dans un atelier de production, la disponibilité des machines dépend de deux éléments que l'on gère souvent séparément : leur fiabilité, et la présence en magasin des pièces nécessaires à leur réparation. Une panne qui survient alors que la pièce est en stock se règle en quelques heures. La même panne en rupture de stock peut immobiliser la machine plusieurs semaines, le temps que le fournisseur livre. À l'inverse, un magasin surdimensionné immobilise un capital important dans des pièces qui ne serviront peut-être jamais.

Les politiques utilisées en pratique reposent le plus souvent sur des seuils fixes : une pièce est recommandée lorsque son stock passe sous un niveau donné, et un composant est remplacé préventivement à intervalle constant. Ces règles sont simples à appliquer, mais elles ignorent l'état réel des machines.

Le projet se place à l'échelle d'une flotte complète. Chaque machine peut être opérationnelle, en panne, en attente d'une pièce ou d'un technicien, en réparation, en maintenance préventive ou en test après intervention, tandis que le stock évolue au rythme des consommations et des livraisons.

1.2 Problématique

Le projet doit répondre à la question suivante : une politique pilotée par l'apprentissage profond, qui anticipe les pannes et décide des commandes et des maintenances préventives, permet-elle de réduire le coût total de la flotte, à disponibilité égale ou supérieure, par rapport à une politique classique à seuils fixes correctement réglée ?

La précision « correctement réglée » a son importance. Comparer un modèle d'apprentissage profond à une politique mal paramétrée surestimerait son apport ; la politique de référence sera donc optimisée avant toute comparaison (§ 7.1).

1.3 Objectifs

Tableau 1. Objectifs du projet et critères d'acceptation

Réf.	Objectif	Livrable	Critère d'acceptation
O1	Préparer et enrichir le jeu de données Azure : durées des étapes, familles de machines, défauts de fabrication, coûts, stock	Jeu de données enrichi, dictionnaire des données	Schéma validé, aucune fuite d'information temporelle
O2	Développer un simulateur à événements discrets couplant flux machine, flux stock et techniciens	Module de simulation testé	Taux de panne d'Azure reproduits à 10 % près
O3	Prédire les pannes et les besoins en pièces	Modèles entraînés, rapport de métriques	Rappel et F1 supérieurs à ceux de LightGBM

Réf.	Objectif	Livrable	Critère d'acceptation
O4	Apprendre une politique de commande et de maintenance préventive par apprentissage par renforcement profond	Agent entraîné	Coût total inférieur à la meilleure politique à seuils fixes, à disponibilité au moins égale
O5	Accélérer l'évaluation de scénarios par un modèle de substitution	Modèle de substitution, analyse de sensibilité	$R^2 > 0{,}9$ sur des scénarios non vus
O6	Restituer les résultats dans une application web	Application déployée, rapport final	Exigences du chapitre 6 satisfaites

Ces critères pourront être ajustés en accord avec l'encadrement.

2 Périmètre et hypothèses

2.1 Périmètre

Le projet porte sur un site de production unique, doté d'un magasin central et d'une équipe de techniciens partagée entre toutes les machines. La chaîne d'approvisionnement amont est représentée par un délai de livraison aléatoire propre à chaque référence de pièce.

Tableau 2. Éléments inclus et exclus du périmètre

Inclus	Exclus
Flotte de 100 machines réparties en deux familles (§ 3.2)	Réseau multi-sites et transferts entre magasins
Quatre composants remplaçables par machine, soit quatre références de pièces	Réparation et remise en stock des pièces usagées
Production, défauts de fabrication et contrôle qualité	Ordonnancement détaillé de la production
Commandes normales et commandes urgentes	Raccordement à une GMAO ou à des capteurs réels
Décisions de commande et de maintenance préventive	
Application web de restitution des résultats	

2.2 Hypothèses de modélisation

H1 Une panne consomme une pièce du composant défaillant ; une maintenance préventive en consomme également une.

H2 Le remplacement remet le composant à neuf. Une variante avec réparation imparfaite pourra être étudiée.

H3 Les machines sont indépendantes, sauf par l'intermédiaire des ressources partagées que sont le stock et les techniciens.

H4 Aucune pièce n'est prélevée sur une machine pour en réparer une autre.

H5 Les décisions de gestion sont prises une fois par jour ; les événements sont simulés à la minute près.

3 Description du système étudié

3.1 Fonctionnement d'une machine et du magasin

Le modèle couple deux flux, en cohérence avec les articles de référence du sujet, qui distinguent les états de la machine, les états du stock et la disponibilité des techniciens. Le flux machine suit la séquence panne, demande de pièce, attente éventuelle, réparation, test puis remise en service. Le flux stock suit la séquence seuil de commande, commande, approvisionnement, réception et mise en stock. Nous avons ajouté un état « attente technicien », absent du sujet, pour rendre compte de la saturation de l'équipe de maintenance.

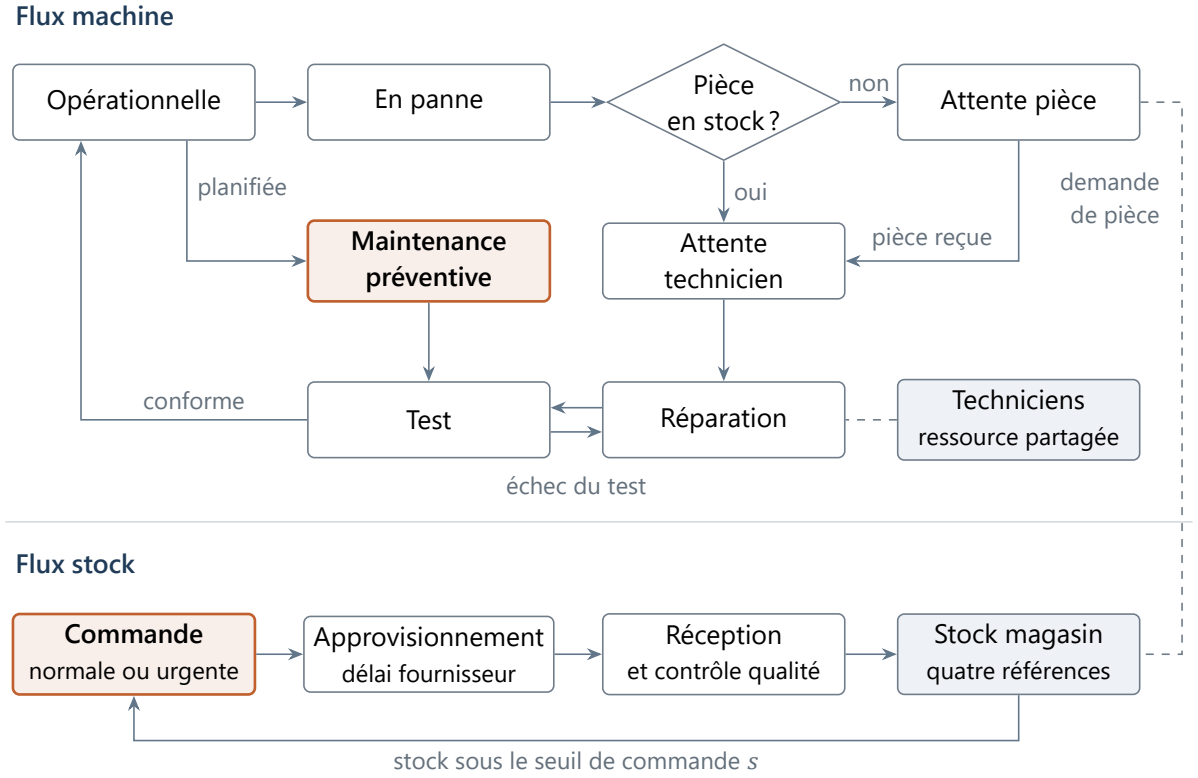


FIGURE 1. Flux machine, flux stock et ressource techniciens. Les cases en couleur sont les deux points où intervient la politique de gestion.

La politique de gestion n'intervient qu'en deux points : le déclenchement d'une maintenance préventive et le passage d'une commande. Le reste du comportement du système découle de ces deux décisions et des aléas que sont les pannes, les délais de livraison et les durées d'intervention.

3.2 Familles de machines et régimes de maintenance

À la demande de l'encadrement, la flotte est composée de deux familles de machines qui se distinguent par leur mode d'usure dominant.

La norme NF EN 13306 [1] définit la maintenance préventive systématique comme une maintenance exécutée « à des intervalles de temps préétablis ou selon un nombre défini d'unités d'usage ». Elle la distingue de la maintenance conditionnelle, déclenchée par une mesure de l'état du bien, et de la maintenance prévisionnelle, déclenchée par une prévision de son évolution. C'est cette dernière que l'apprentissage profond doit permettre de mettre en œuvre. Le tableau 3 résume les régimes retenus.

Tableau 3. Régimes de maintenance pris en compte

Régime	Déclenchement	Unité	Politique associée [2]
Corrective	Panne	Sans objet	Sans objet
R1 Systématique à l'usage	Compteur atteignant N	Cycles, tours, heures de marche	Remplacement selon l'âge
R2 Systématique calendaire	Date atteignant T	Jours, mois, années	Remplacement par blocs
R3 Conditionnelle	Mesure dépassant un seuil	Vibration, pression, tension, taux de défauts	Seuil d'alarme
R4 Prévisionnelle	Risque prédit dépassant un seuil, ou décision de l'agent	Probabilité de panne	Politique étudiée dans ce projet

Famille U, usage intensif

Ces machines s'usent en fonction du nombre de cycles réalisés : presses dont on compte les coups, machines-outils dont on compte les heures de broche. La durée de vie d'un roulement, par exemple, s'exprime en millions de tours [3]. Leurs composants principaux suivent le régime R1, et elles fonctionnent sur deux ou trois postes par jour.

Famille C, vieillissement calendaire

Certains éléments de ces machines vieillissent même à l'arrêt : joints et flexibles hydrauliques, lubrifiants, isolants, ou équipements soumis à des contrôles réglementaires périodiques. Leurs composants principaux suivent le régime R2, une révision générale est programmée tous les 5 ou 10 ans, et elles fonctionnent sur un ou deux postes par jour.

Trois précisions complètent ce découpage. D'abord, la famille indique le régime dominant et non un régime unique : au sein d'une même machine, chaque composant conserve son propre régime. Ensuite, une échéance de 5 ou 10 ans dépasse l'année d'historique disponible ; elle est donc positionnée à partir de l'âge de la machine, qui varie de 0 à 20 ans dans Azure, la prochaine révision tombant au prochain multiple de l'intervalle. Enfin, une maintenance systématique n'a d'intérêt que si le taux de panne croît avec l'âge du composant, c'est-à-dire si le paramètre de forme de la loi de Weibull vérifie $\beta > 1$. Ce point sera contrôlé composant par composant lors de l'analyse exploratoire.

Une flotte de machines identiques, notée S0, est conservée comme cas de validation du simulateur. La flotte à deux familles constitue le scénario principal S1.

3.3 Défauts de fabrication

Chaque machine produit des pièces pendant ses heures d'ouverture. Lorsqu'un composant se dégrade, la proportion de pièces défectueuses augmente : une machine en fin de vie produit du rebut avant de tomber en panne. Ces défauts de fabrication sont à distinguer des erreurs machine présentes dans Azure, qui sont des alarmes non bloquantes.

La probabilité qu'une pièce produite soit défectueuse est modélisée par

$$p(t) = p_0 + \sum_{k=1}^{4} a_k \, D_k(t)^{\gamma}$$

où p_0 est le taux de défaut indépendant de la machine (matière, opérateur), $D_k(t) \in [0,1]$ la dégradation du composant k, a_k sa contribution, et $\gamma > 1$ traduit l'accélération des défauts en fin de vie.

Chaque composant est associé à un type de défaut (dimensionnel, état de surface, assemblage, aspect), si bien que le type de défaut observé devient un indice de diagnostic. Les pièces sont contrôlées par prélèvement d'une pièce sur vingt ; une pièce défectueuse détectée est mise au rebut ou retouchée. Après chaque intervention, un lot d'essai de cinq pièces est produit et le test échoue si l'une d'elles est défectueuse. Avec $p_0 = 1\ \%$, le taux d'échec du test vaut $1 - 0{,}99^5 \approx 4{,}9\ \%$.

Ce mécanisme a trois conséquences. La maintenance préventive devient utile même lorsqu'aucune panne n'est imminente, puisqu'elle restaure la qualité. Une dérive du taux de défauts peut servir de déclencheur à la maintenance conditionnelle. Enfin, le taux de rendement synthétique (TRS) devient l'indicateur principal de l'évaluation.

4 Données

4.1 Jeu de données de référence

Nous utilisons le jeu de données Microsoft Azure Predictive Maintenance [4], qui décrit 100 machines sur l'année 2015.

Tableau 4. Contenu du jeu de données Azure

Fichier	Contenu	Volume	Utilisation
PdM_telemetry	Tension, vitesse de rotation, pression et vibration, moyennées par heure	876 100 lignes	Entrées du module de prédiction, calibration de la télémétrie simulée
PdM_errors	Erreurs non bloquantes de cinq types	environ 3 900 lignes	Signes précurseurs de panne

Fichier	Contenu	Volume	Utilisation
PdM_maint	Remplacements de composants, planifiés ou non, depuis 2014	environ 3 300 lignes	Âge des composants, durées de vie censurées
PdM_failures	Pannes suivies d'un remplacement (comp1 à comp4)	761 lignes	Étiquettes, lois de panne, demande en pièces
PdM_machines	Modèle (quatre modèles) et âge de chaque machine	100 lignes	Attributs des machines, affectation aux familles

Les volumes approximatifs seront confirmés lors de l'analyse exploratoire. Ce jeu de données présente plusieurs limites que l'enrichissement doit corriger :

- il est lui-même synthétique, ce qui fait de ce projet un démonstrateur méthodologique et non une étude de cas industrielle ;
- une panne et le remplacement qui la suit portent le même horodatage, de sorte qu'aucune durée d'intervention n'est observable ;
- il ne contient aucune information sur le stock, les commandes, les coûts, les techniciens ou la production ;
- l'historique ne couvre qu'une année ;
- les machines tournent 24 heures sur 24, ce qui empêche de distinguer l'usure par l'usage du vieillissement calendaire ;
- les pannes sont rares, environ 0,09 % des heures-machine, ce qui exclut l'exactitude (*accuracy*) comme métrique.

4.2 Durées des étapes du processus

Nous distinguons deux natures de durées. Les durées intrinsèques, comme le diagnostic, la réparation, le test ou le délai fournisseur, caractérisent le travail à effectuer : elles sont ajoutées sous forme de lois de probabilité. Les durées d'attente, qu'il s'agisse d'attendre une pièce ou un technicien, dépendent au contraire de la politique de gestion et sont produites par le simulateur. Si elles étaient figées dans les données, aucune politique ne pourrait les réduire.

Tableau 5. Durées des étapes et lois de probabilité retenues

Étape	Nature	Loi	Valeur de départ
Détection et diagnostic	Intrinsèque	Lognormale	1 h en moyenne
Attente d'un technicien	Produite par le simulateur	Sans objet	Selon la charge
Attente d'une pièce	Produite par le simulateur	Sans objet	Nulle si la pièce est en stock
Sortie magasin	Intrinsèque	Triangulaire	0,5 h
Réparation corrective	Intrinsèque, par composant	Lognormale	4 à 12 h

Étape	Nature	Loi	Valeur de départ
Maintenance préventive	Intrinsèque, par composant	Lognormale	60 % de la réparation corrective
Test après intervention	Intrinsèque	Triangulaire	1 à 2 h, échec selon le lot d'essai
Traitement d'une commande	Intrinsèque	Constante	4 h
Délai fournisseur	Intrinsèque, par pièce	Gamma	3 jours à 8 semaines (tableau 6)
Réception et contrôle	Intrinsèque	Triangulaire	2 h
Révision générale, famille C	Intrinsèque	Lognormale	2 à 5 jours

La loi lognormale est le choix habituel pour les temps de réparation, la loi gamma pour les délais. En l'absence de données réelles, ces valeurs de départ seront soumises à l'analyse de sensibilité (§ 5.4) et remplacées si l'encadrement fournit des valeurs mesurées.

4.3 Pièces, coûts et ressources

Les coûts sont exprimés en unités relatives (UR), 1 UR correspondant au prix d'une pièce catalogue. Ce sont en effet les rapports entre coûts, et non leurs montants, qui orientent les décisions ; une conversion en dirhams ou en euros reste possible pour la présentation des résultats.

Tableau 6. Références de pièces de rechange

Réf.	Nature	Prix	Délai normal	Délai urgent
P1	Pièce d'usure catalogue (roulement)	1 UR	3 à 7 jours	1 jour
P2	Pièce d'usure catalogue (kit de joints)	1 UR	3 à 7 jours	1 jour
P3	Pièce usinée spécifique	50 UR	3 à 6 semaines	1 semaine
P4	Sous-ensemble (moteur, carte de commande)	200 UR	4 à 8 semaines	1 à 2 semaines

Les références seront affectées aux composants après l'analyse exploratoire : les composants les plus souvent défaillants recevront les pièces catalogue, les plus rarement défaillants les pièces coûteuses, comme c'est généralement le cas en milieu industriel. Le kit de révision générale de la famille C, dont la date d'utilisation est connue à l'avance, est commandé en conséquence et reste hors de la gestion de stock.

Tableau 7. Paramètres de coût

Paramètre	Valeur de départ	Justification
Possession du stock	25 % de la valeur de la pièce par an	Ordre de grandeur usuel, entre 20 et 30 %
Commande	2 UR par commande	Incite à grouper les commandes de pièces catalogue
Commande urgente	Prix unitaire × 2,5	Majoration usuelle comprise entre 2 et 3

Paramètre	Valeur de départ	Justification
Main-d'œuvre	0,5 UR par heure, heures supplémentaires × 1,5	Hypothèse
Intervention corrective	Deux fois le coût de la préventive équivalente, hors arrêt	Intervention non planifiée et dommages induits ; rapport testé entre 1,5 et 3
Arrêt d'une machine	Marge perdue, environ 1 UR par heure d'ouverture	Cadence multipliée par la marge par pièce
Rebut	0,1 UR par pièce	Matière et temps machine perdus
Retouche	0,03 UR et 5 min par pièce	Moins coûteuse que le rebut
Rupture de stock	Pas de pénalité propre	Son coût est celui de l'arrêt qu'elle provoque

Tableau 8. Paramètres de production par famille

Paramètre	Famille U	Famille C
Postes de 8 h par jour	2 ou 3	1 ou 2
Cadence	60 pièces par heure	20 pièces par heure
Taux de défaut de base p_0	1 %	1 %
Contrôle en ligne	1 pièce sur 20	1 pièce sur 20
Lot d'essai après intervention	5 pièces	5 pièces

L'effectif de techniciens sera fixé après l'analyse exploratoire, de façon à obtenir une charge moyenne voisine de 75 %.

Les coûts de départ seront enfin ajustés une fois le simulateur construit, afin que la meilleure politique à seuils fixes connaisse encore 2 à 10 % de ruptures. Sans cette précaution, conserver un stock abondant serait toujours la meilleure décision et le problème perdrait son intérêt.

4.4 Modèle de données

Tableau 9. Tables du jeu de données enrichi

Table	Grain	Contenu principal	Origine
machines	Une ligne par machine	Modèle, âge, famille, postes, cadence, taux de défaut de base, échéance de révision	Azure et ajouts
components	Modèle et composant	Régime, intervalle de maintenance, paramètres de Weibull, signal précurseur, lois de durée, type de défaut	Calibration et hypothèses
parts	Une ligne par référence	Classe, prix, lois de délai, paramètres de stock	Hypothèses
technicians	Équipe	Effectif, calendrier, coût horaire	Hypothèses

Table	Grain	Contenu principal	Origine
production	Machine et heure	Pièces produites, défectueuses, rebutées, retouchées	Simulateur, Azure enrichi
quality_events	Un défaut détecté	Type, quantité, composant suspecté, décision	Simulateur
events	Un événement	Horodatage, machine, type d'événement, durée, coût	Simulateur
state_intervals	Un séjour dans un état	Machine, état, début, fin, cause	Simulateur
ml_features	Machine et heure	Variables d'apprentissage et étiquettes	Azure et simulateur

La table `ml_features` regroupe les variables suivantes :

- statistiques glissantes des quatre signaux, moyenne et écart-type sur 3 h et 24 h ;
- nombre d'erreurs par type sur 24 h, taux de défauts sur 8 h et 24 h ;
- pour chaque composant, temps écoulé depuis le dernier remplacement en heures calendaires, en heures de marche et en millions de tours, ce dernier compteur étant obtenu en cumulant le signal de rotation pendant les heures de marche ;
- distance à la prochaine échéance de maintenance de chaque composant ;
- attributs de la machine : âge, modèle, famille, taux d'utilisation ;
- contexte logistique : stock disponible, commandes en cours et dates d'arrivée prévues ;
- étiquettes : panne du composant dans les 24 h, 48 h et 7 jours, et temps jusqu'à la panne avec indicateur de censure.

5 Solution proposée

5.1 Simulateur à événements discrets

Le simulateur est le socle du projet : il génère les données synthétiques, sert d'environnement d'apprentissage à l'agent et arbitre la comparaison des politiques. Développé avec SimPy, il comprend :

- un processus par machine, qui parcourt les états de la figure 1 et journalise chaque transition ;
- un modèle de dégradation par composant, fonction de l'usage (R1) ou du temps (R2), dont les pannes suivent une loi de Weibull calibrée sur Azure ;
- un générateur de télémétrie, qui superpose au niveau de base observé dans Azure une dérive proportionnelle à la dégradation et un bruit aléatoire ;
- un module de production et de qualité conforme au § 3.3 ;
- le magasin, avec ses stocks, ses commandes en cours et sa file de demandes ;

- l'équipe de techniciens, ressource limitée soumise à un calendrier de postes ;
- une interface de pilotage qui, chaque jour, expose l'état du système, reçoit les décisions puis fait avancer la simulation jusqu'au lendemain.

Calibration et validation

Les lois de Weibull sont ajustées sur les durées séparant deux remplacements dans Azure. Les remplacements planifiés y sont traités comme des observations censurées à droite, ce qui évite de sous-estimer la durée de vie des composants. L'influence du modèle et de l'âge de la machine est prise en compte par un modèle de Weibull à temps de vie accéléré.

Le simulateur est validé en rejouant la politique observée dans Azure : le nombre de pannes par composant doit être reproduit à 10 % près, et les distributions des signaux sont comparées par un test de Kolmogorov-Smirnov. Un test TSTR [5], qui consiste à entraîner un modèle sur données simulées puis à le tester sur données réelles, vérifie enfin que les données produites restent représentatives.

Exigences techniques

Chaque réplication dispose de sa propre graine aléatoire, et les politiques comparées partagent les mêmes nombres aléatoires. Une année simulée pour 100 machines doit s'exécuter en moins de deux secondes, condition nécessaire à l'apprentissage par renforcement. Tous les paramètres sont regroupés dans des fichiers de configuration.

5.2 Module de prédiction

Plutôt qu'une simple classification « panne ou non dans les 24 heures », le module estime pour chaque composant la probabilité de panne pour chacun des 14 jours à venir, selon un modèle de survie en temps discret [6]. Cette forme de sortie répond directement au besoin de la gestion de stock : la demande attendue d'une pièce sur le délai fournisseur L s'obtient en sommant, sur l'ensemble des machines, les probabilités de panne avant L, auxquelles s'ajoutent les maintenances préventives programmées. Les entrées sont une fenêtre glissante de 48 heures des variables de la table `ml_features` et les attributs statiques de la machine.

Tableau 10. Modèles de prédiction comparés

Modèle	Famille	Rôle
Régression logistique	Apprentissage classique	Référence minimale
LightGBM [7]	Gradient boosting	Référence à dépasser
LSTM [8]	Réseau récurrent	Modèle cité par le sujet
GRU [9]	Réseau récurrent	Candidat principal
TCN [10]	Convolutions temporelles dilatées	Candidat principal
Transformer	Mécanisme d'attention	Piste complémentaire

Avec 761 pannes seulement, les architectures légères (GRU, TCN) sont privilégiées ; un Transformer risquerait le surapprentissage et ne sera essayé que si le calendrier le permet.

Protocole

- Découpage temporel strict : apprentissage de janvier à août, validation en septembre et octobre, test en novembre et décembre, complété par un test sur des machines non vues.
- Perte pondérée ou perte focale [11] pour compenser le déséquilibre des classes.
- Calibration des probabilités (*temperature scaling* ou régression isotone), contrôlée par le score de Brier, puisque ces probabilités alimentent ensuite les décisions.
- Métriques : rappel, précision, F1 et aire sous la courbe précision-rappel par composant, délai d'anticipation des alertes, indice de concordance pour les courbes de survie.
- Réglage des hyperparamètres avec Optuna.

5.3 Agent d'apprentissage par renforcement

Le problème de décision est formulé comme un processus de décision markovien à pas journalier, chaque épisode couvrant une année d'exploitation.

L'observation comprend, pour chaque référence, le stock disponible, les commandes en cours et les demandes en attente ; pour chaque machine, son état, le temps écoulé depuis les derniers remplacements, la distance aux échéances de maintenance, le risque prédit et le taux de défauts récent ; au niveau global, le nombre de techniciens disponibles et le jour de l'année. La récompense est l'opposé du coût de la journée, qui additionne les coûts de stockage, de commande, d'intervention, d'arrêt et de non-qualité définis au § 4.3.

Deux niveaux d'ambition sont prévus. Au niveau N1, l'agent fixe chaque jour, pour chaque composant, un seuil de risque déclenchant la maintenance préventive et un niveau de recomplètement du stock ; une règle simple exécute ensuite ces consignes. L'espace d'actions reste réduit, l'apprentissage est stable et la politique obtenue s'interprète facilement. Au niveau N2, l'agent décide directement des quantités commandées, des commandes urgentes et des maintenances, machine par machine. Le niveau N1 est un livrable garanti ; le niveau N2 sera traité si le calendrier le permet.

L'agent principal repose sur l'algorithme PPO [12] avec masquage des actions invalides [13] : le masque interdit par exemple une maintenance sur une machine déjà en panne, ou en l'absence de pièce en stock. Un DQN [14] classique devrait énumérer toutes les combinaisons d'actions, dont le nombre explose avec la taille de la flotte. Pour la comparaison avec cette famille d'algorithmes, nous retenons donc une architecture à branches [15], qui traite chaque dimension de l'action séparément.

Tableau 11. Algorithmes d'apprentissage par renforcement étudiés

Algorithme	Rôle dans l'étude
MaskablePPO	Agent principal, niveaux N1 et N2
PPO sans masque	Mesure de l'apport du masquage
DQN, variantes Double et Dueling	Comparaison sur le niveau N1
Branching Dueling Q-Network	Comparaison sur le niveau N2

Algorithme	Rôle dans l'étude
RecurrentPPO	Variante si l'observabilité partielle pénalise l'agent

L'entraînement s'appuie sur 8 à 16 simulateurs exécutés en parallèle et sur un apprentissage progressif, d'abord sur 10 machines puis sur la flotte complète. Chaque configuration est entraînée avec au moins trois graines différentes afin de rendre compte de la variabilité des résultats.

5.4 Modèle de substitution

Le modèle de substitution apprend la relation entre les paramètres d'un scénario et ses indicateurs de performance. Il est construit à partir de 2 000 à 5 000 scénarios tirés selon un plan en hypercube latin et simulés cinq fois chacun. Ses entrées regroupent les paramètres de politique (seuils de stock, intervalles de maintenance, seuil de risque) et les paramètres du système (nombre de techniciens, délais, taux de panne, coûts) ; ses sorties sont les indicateurs du § 7.2.

Le modèle principal est un ensemble de cinq réseaux de neurones [16], qui fournit à la fois une prédiction et une mesure d'incertitude. Un processus gaussien et LightGBM servent de comparaison. La qualité du modèle est mesurée par le R^2 et l'erreur relative moyenne sur des scénarios non vus, et tout optimum qu'il propose est vérifié par simulation.

Le modèle de substitution remplit trois fonctions : optimiser la politique à seuils fixes par optimisation bayésienne, conduire l'analyse de sensibilité globale par les indices de Sobol [17] sur les hypothèses du chapitre 4, et fournir des réponses instantanées à la page « Scénarios » de l'application web.

6 Application web

6.1 Objectif

L'application web permet à un responsable maintenance, et lors de la soutenance au jury, d'explorer les données, de suivre une simulation en direct, de consulter les prédictions et de comparer les politiques. Elle est conçue comme un produit à part entière : une identité visuelle propre est définie, et des maquettes sont validées avant le début du développement.

Les outils de tableau de bord écrits en Python (Streamlit, Dash) ont été écartés. Ils sont rapides à mettre en œuvre, mais limitent fortement la mise en page et l'animation. Une interface React donne au contraire un contrôle complet du rendu, ce qui est nécessaire pour animer la flotte et soigner la présentation.

6.2 Exigences fonctionnelles

Tableau 12. Exigences fonctionnelles de l'application

Réf.	Exigence	Priorité
EF-01	Tableau de bord des indicateurs clés de la flotte : TRS, disponibilité, coût cumulé, ruptures et alertes en cours	Haute
EF-02	Lancement d'une simulation (politique, scénario, graine) et suivi en direct de la flotte : état de chaque machine, stocks, file des techniciens, vitesse réglable	Haute
EF-03	Fiche machine : historique des états, télémétrie, courbes de risque par composant, défauts récents	Haute
EF-04	Suivi du stock : niveau par référence, commandes en cours, ruptures et leur durée	Haute
EF-05	Comparaison des politiques P0 à P5 : indicateurs avec intervalles de confiance et front de Pareto entre coût et TRS	Haute
EF-06	Scénarios « et si » : réglage des paramètres par curseurs et réponse immédiate du modèle de substitution	Moyenne
EF-07	Exploration du jeu de données enrichi, filtrable par machine, famille et composant	Moyenne
EF-08	Export des tableaux au format CSV et des graphiques au format PNG	Basse

6.3 Exigences non fonctionnelles

Tableau 13. Exigences non fonctionnelles de l'application

Réf.	Domaine	Exigence
ENF-01	Ergonomie	Interface en français, réalisée à partir de maquettes Figma et d'un guide de style (palette, typographie, composants)
ENF-02	Performance	Réponse du modèle de substitution en moins de 300 ms ; affichage d'une année simulée en moins de 2 s en mode accéléré
ENF-03	Compatibilité	Navigateurs récents ; mise en page adaptée aux écrans d'ordinateur et de tablette, à partir de 768 pixels de large
ENF-04	Architecture	Le serveur ne réentraîne aucun modèle : il charge les modèles sauvegardés et ne lance que des simulations courtes
ENF-05	Déploiement	Lancement local par Docker Compose ; version de démonstration accessible par un lien public
ENF-06	Qualité	Tests de l'API (pytest), des composants (Vitest) et du parcours principal (Playwright)

6.4 Architecture

L'application se compose d'une interface monopage développée en React et d'une API FastAPI qui expose le moteur Python. Les échanges courants passent par une API REST. La simulation en direct est transmise jour après jour par WebSocket, ce qui permet d'animer la flotte sans attendre la fin du calcul. La figure 2 situe l'application dans l'ensemble du projet.

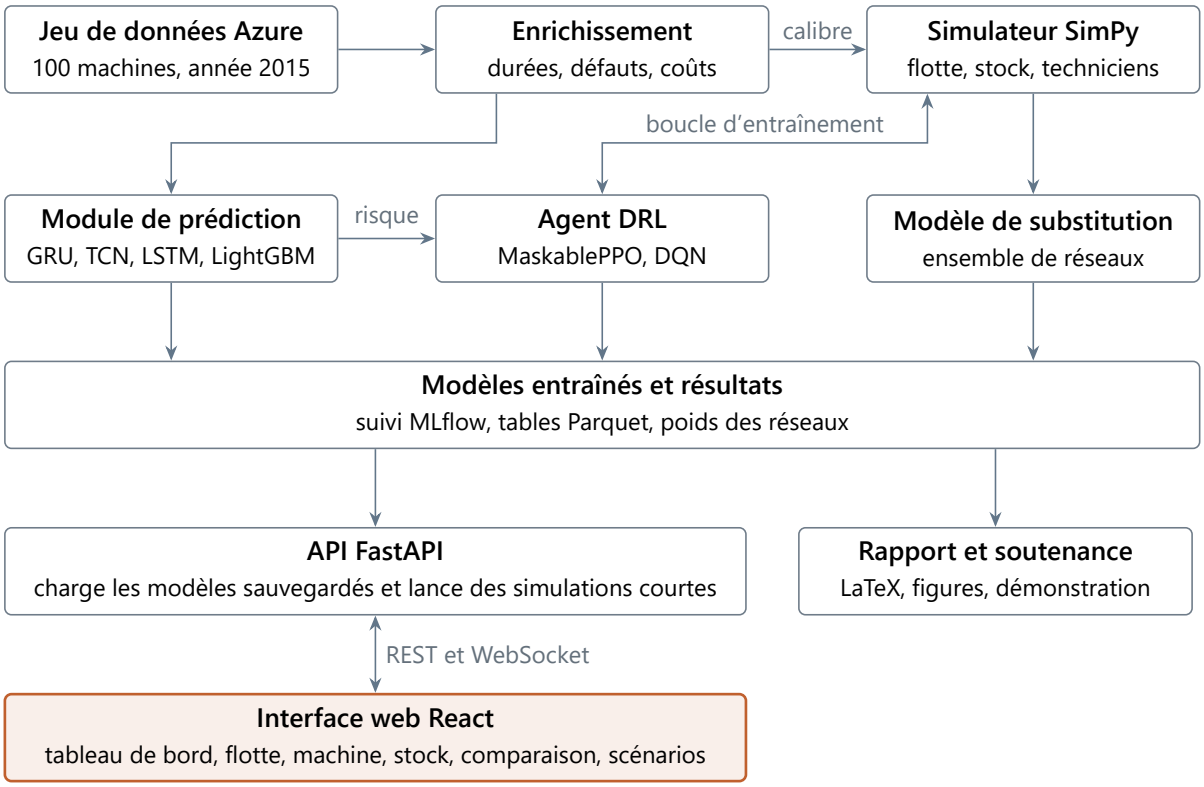


Figure 2. Architecture d'ensemble, du jeu de données à l'interface web.

7 Évaluation

7.1 Politiques comparées

Tableau 14. Politiques de gestion comparées

Code	Politique	Gestion du stock	Maintenance préventive
P0	Seuils fixes réglés à la main	(s, S) fixés par l'expérience	Systématique, intervalles constructeur
P1	Seuils fixes optimisés	(s, S) optimisés	Systématique, intervalles optimisés
P2	Maintenance conditionnelle	(s, S) optimisés	Seuil sur une mesure ou sur le taux de défauts
P3	Prédictive sans apprentissage par renforcement	Recomplètement selon la demande prédite	Risque prédit supérieur à un seuil fixe
P4	Agent DRL, niveau N1	Fixée par l'agent	Seuil de risque fixé par l'agent
P5	Agent DRL, niveau N2	Fixée par l'agent	Décidée par l'agent
Oracle	Connaissance des pannes futures	Idéale	Idéale

La politique P1 est la référence principale. P3 isole l'apport de la prédiction seule, P4 et P5 celui de l'apprentissage par renforcement, et l'oracle fournit une borne qu'aucune politique réaliste

ne peut dépasser.

7.2 Indicateurs de performance

Tableau 15. Indicateurs de performance

Indicateur	Définition	Unité
TRS	Disponibilité × performance × qualité	%
Disponibilité	Temps opérationnel rapporté au temps d'ouverture	%
Taux de défauts	Pièces défectueuses rapportées aux pièces produites	%
Attente de pièce	Durée moyenne d'attente de pièce par intervention	h
Fréquence de ruptures	Demandes non servies immédiatement, rapportées au total des demandes	%
Coût total	Stockage, commandes, interventions, arrêts et non-qualité	UR par an
Stock immobilisé	Valeur moyenne du stock	UR
MTBF, MTTR	Temps moyen entre pannes, temps moyen de réparation	h
Qualité de prédiction	Rappel, précision, F1, aire sous la courbe précision-rappel	Sans unité

7.3 Protocole expérimental

Chaque politique est évaluée sur 30 réplications d'une année, avec des nombres aléatoires communs, et les résultats sont présentés avec leurs intervalles de confiance à 95 %. Les écarts entre P1 et les politiques fondées sur l'apprentissage sont testés par un test de Wilcoxon apparié, et les compromis entre coût et TRS sont visualisés sur un front de Pareto.

La robustesse de l'agent, entraîné sur le scénario nominal, est ensuite évaluée dans quatre situations : un délai fournisseur doublé, un taux de panne augmenté de 30 %, un technicien de moins, et la flotte homogène S0.

8 Choix techniques

Tableau 16. Outils retenus

Domaine	Outils
Langage et environnement	Python 3.11, gestionnaire uv
Données	pandas, format Parquet
Simulation	SimPy, interface Gymnasium
Apprentissage profond	PyTorch
Apprentissage par renforcement	Stable-Baselines3 et sb3-contrib [18]

Domaine	Outils
Apprentissage classique et fiabilité	scikit-learn, LightGBM, lifelines
Optimisation et sensibilité	Optuna, SciPy, SALib
Suivi des expériences	MLflow, TensorBoard
API	FastAPI, Pydantic, WebSocket
Interface	React et TypeScript (Vite), Tailwind CSS, shadcn/ui, Apache ECharts, TanStack Query
Maquettes	Figma
Qualité	pytest, Vitest, Playwright, ruff, GitHub Actions
Déploiement	Docker Compose ; Vercel pour l'interface, Render ou Hugging Face Spaces pour l'API
Rapport	LaTeX

L'ensemble des traitements fonctionne sur processeur ; une carte graphique accélère seulement l'entraînement des modèles de prédiction. Le choix d'un même langage pour le simulateur, les modèles et l'API évite toute conversion entre environnements.

9 Organisation du projet

9.1 Livrables

Tableau 17. Découpage en lots et livrables

Lot	Contenu	Livrable
L0 Cadrage	Rédaction et validation du cahier des charges	Cahier des charges validé
L1 Données	Analyse exploratoire, calibration, enrichissement	Jeu de données enrichi, dictionnaire des données
L2 Simulation	Simulateur et politiques P0 à P2	Module testé, rapport de validation
L3 Prédiction	Modèles LightGBM, LSTM, GRU et TCN	Modèles entraînés, rapport de métriques
L4 Décision	Agents DRL N1 puis N2, politique P3	Agents entraînés, courbes d'apprentissage
L5 Substitution	Modèle de substitution, sensibilité, optimisation de P1	Modèle validé, indices de Sobol
L6 Application	Maquettes, API et interface	Application déployée
L7 Restitution	Évaluation finale, rapport, soutenance	Rapport et présentation

9.2 Planning prévisionnel

Le planning suppose un démarrage la semaine du 2 novembre 2026 et sera recalé sur la date de soutenance. Les lots L2 et L3 sont menés en parallèle. Le développement de l'application avance d'abord sur des données fictives, puis se raccorde à l'API dès que les modèles sont disponibles. Le lot L5 doit être terminé avant l'évaluation finale, puisqu'il fournit la politique de référence optimisée.

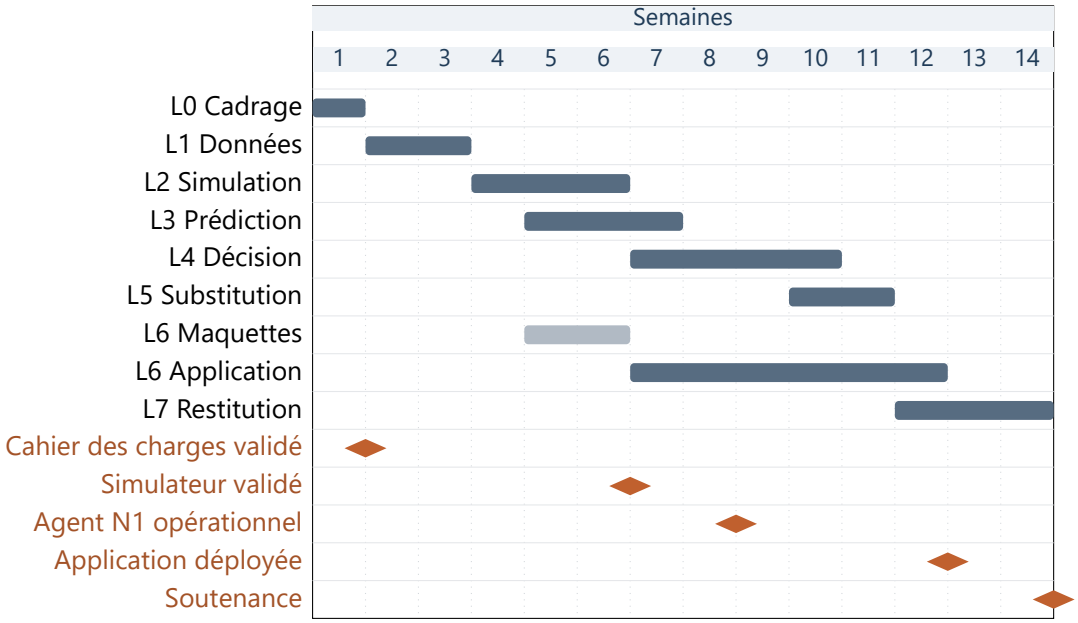


Figure 3. Planning prévisionnel, en semaines à partir du 2 novembre 2026.

9.3 Risques

Tableau 18. Principaux risques et parades

Risque	Prob.	Impact	Parade
L'agent ne dépasse pas la politique optimisée	Moyenne	Élevé	Niveau N1 en priorité, récompense normalisée ; un résultat négatif argumenté reste exploitable
Problème trop facile, un stock abondant suffit	Moyenne	Élevé	Ajustement des coûts décrit au § 4.3
Simulateur trop lent pour l'apprentissage	Moyenne	Élevé	Mesure des performances dès L2, pas journalier, simulations parallèles
Données simulées trop faciles à prédire	Moyenne	Moyen	Bruit et variabilité entre machines, test TSTR
Hypothèses de coûts et de durées contestées	Moyenne	Moyen	Unités relatives, valeurs usuelles, analyse de sensibilité
Fuite d'information dans la prédiction	Faible	Élevé	Découpage temporel strict, variables calculées sur le passé seulement
Retard sur l'application web	Moyenne	Moyen	Maquettes validées tôt, développement sur données fictives en parallèle

Risque	Prob.	Impact	Parade
Dérive du périmètre	Élevée	Moyen	Pistes complémentaires réservées aux perspectives

10 Points restant à préciser

Les éléments suivants seront arrêtés avec l'encadrement :

- la composition de l'équipe et la répartition des lots ;
- la date de soutenance et les éventuels jalons intermédiaires ;
- les articles de référence cités dans le sujet, qui permettront d'aligner nos notations et, le cas échéant, de remplacer les valeurs de départ du chapitre 4 ;
- les attentes concernant les défauts de fabrication : types de défauts, choix entre rebut et retouche, ordre de grandeur du taux de défaut.

Références

[1] AFNOR, *NF EN 13306, Maintenance. Terminologie de la maintenance*, 2018.

[2] R. E. Barlow et F. Proschan, *Mathematical Theory of Reliability*, Wiley, 1965.

[3] ISO, *ISO 281, Roulements. Charges dynamiques de base et durée nominale*, 2007.

[4] Microsoft Azure Predictive Maintenance, jeu de données publié sur Kaggle, https://www.kaggle.com/datasets/arnabbiswas1/microsoft-azure-predictive-maintenance.

[5] C. Esteban, S. L. Hyland et G. Rätsch, « Real-valued (medical) time series generation with recurrent conditional GANs », arXiv:1706.02633, 2017.

[6] M. F. Gensheimer et B. Narasimhan, « A scalable discrete-time survival model for neural networks », *PeerJ*, 7:e6257, 2019.

[7] G. Ke et al., « LightGBM: A highly efficient gradient boosting decision tree », *NeurIPS*, 2017.

[8] S. Hochreiter et J. Schmidhuber, « Long short-term memory », *Neural Computation*, 9(8), 1997.

[9] K. Cho et al., « Learning phrase representations using RNN encoder-decoder for statistical machine translation », *EMNLP*, 2014.

[10] S. Bai, J. Z. Kolter et V. Koltun, « An empirical evaluation of generic convolutional and recurrent networks for sequence modeling », arXiv:1803.01271, 2018.

[11] T.-Y. Lin et al., « Focal loss for dense object detection », *ICCV*, 2017.

[12] J. Schulman et al., « Proximal policy optimization algorithms », arXiv:1707.06347, 2017.

[13] S. Huang et S. Ontañón, « A closer look at invalid action masking in policy gradient algorithms », *FLAIRS*, 2022.

[14] V. Mnih et al., « Human-level control through deep reinforcement learning », *Nature*, 518, 2015.

[15] A. Tavakoli, F. Pardo et P. Kormushev, « Action branching architectures for deep reinforcement learning », *AAAI*, 2018.

[16] B. Lakshminarayanan, A. Pritzel et C. Blundell, « Simple and scalable predictive uncertainty estimation using deep ensembles », *NeurIPS*, 2017.

[17] A. Saltelli et al., *Global Sensitivity Analysis: The Primer*, Wiley, 2008.

[18] A. Raffin et al., « Stable-Baselines3: Reliable reinforcement learning implementations », *Journal of Machine Learning Research*, 22(268), 2021.